

画像認識ニューラルネットワークによる複数ロボットの対面走行

○李 方正 (室蘭工業大学), 山田 将司 (室蘭工業大学), 本田 泰 (室蘭工業大学)

The Face-To-Face Movement of Multiple Robots Based on Image Analysis Neural Network

○Li Fangzheng (Muroran Institute of Technology), Masashi Yamada (Muroran Institute of Technology), Yasushi Honda (Muroran Institute of Technology)

Abstract:

In previous research, we did some pseudo-ellipse course experiments of Face-to-Face movement with sensory motor mapping robots based on tanh function. Then, we confirmed the transference phenomenon from Face-to-Face movement to one-direction flow and measure the flow rate and time from start to one-direction flow.

In this paper, in order to shun one-direction flow, we made neural network model (input:960, middle:1000, output:2) which can analyse one-dimension image data and did about five experiments of neural network model and sensory motor mapping model in same course. From those experiments we know the robots can avoid obstacles smoothly and keep Face-to-Face movement for a long time successfully. Beside, we also proved the neural network model is better than sensory motor mapping model in robots flow rate, time of keep one-direction flow and turn around number through compare between two model.

Keywords: Neural Network, Conly Robots, Face-To-Face Monement, sensory motor mapping

1 はじめに

実世界で、蜂、アリなどの昆虫が簡単な行動メカニズムによって、複雑な群れ行為がよく観察される。また、大きな交差点などにおいて、人間は密度が高くても、会話なしで、ぶつからないようにスムーズに対面歩行ができる。我々は、走行ロボットを使って、様々な自律走行アルゴリズムで対面走行実験を行って、その対面走行など、自己組織化のメカニズムを解明することに目指す。

先行研究 [2] では、我々は双曲線関数により、距離センサとモーターの出力が直接関連する感覚運動写像 (省略名: SMM) ロボットを使って、擬楕円コースで8台のロボットの対面走行の実験を行った。結果として、コース幅の増加に従って、流量が増加して、コース幅が56cmから安定になると確認した。初期配置と初期向きを問わず、一定時間結果後、すべてのロボットが同じ方向になって、1方向走行流が観察された。理由として、距離データで向きを判断できないと考えている。それに、3つの距離データで障害物の数を認識できず、渋滞が起こることの原因になると考える。

本研究では、長時間対面走行ができ、流量を増やせるようにするため、カメラを使って、中間層1層のニューラルネットワーク (省略名: NN) により1次元画像認識アルゴリズムを開発した。コースに色をつけ、感覚運動写像とニューラルネットワーク2種類のアルゴリズムでコース幅1mの8台ロボットの対面走行を実験した。

結果として、ラジコンする時、ソースコード上曲がる値を拡大、直接後退機能をつければ、ニューラルネットワークより自律走行性能が向上するといった。一方、方向転換のことをロボットに教えてないまま、1方向走行流になりにくく、感覚運動写像より、ニューラルネット

ワークの方が壁や障害物 (他のロボット) をスムーズに避けることができると観察した、流量も1.5になると確認した。

2 ロボットの身体性

今回使っているのはラズパイで制御する4輪走行ロボットである (Fig.2), 人間や昆虫の走行特徴に近似するため、その場で曲がり、方向転換が可能である。ロボットの頭にカメラ (D) をつけていて、入力データを収集する。E, F は左右のモーター、独自で左右の車輪を制御して、ロボットを動かす。A, B, C は右、中央、左の距離センサ、先行研究で使っていたが、本文は使っていない。ロボット幅は13.5cm。長さは20.2cm。高さは12.2cmである。




Fig. 1 ロボット正面図

3 ニューラルネットワーク

3.1 教師データの収集

本研究では、二次元画像データ (RGB) のピクセル値を縦方向 (y 方向) にすべて足し合わせて一次元画像をつ

くる．それらを並べたものを1次元画像ベクトル \vec{u} とする (1 式参照)．

具体的に記述する．カメラで撮影するのは 320×240 のサイズのピクセル値であるが，不要な部分を切り取って，約 130 行目から 200 行目を切り出す．コースの壁や障害物となる走行ロボット以外が撮影されている上下の部分を不要な部分とみなす．つまりコース以外とロボット自身が映ってる部分をトリミングする (Fig.3 参照)．

その画像データの Red, Green, Blue それぞれのピクセル値を要素としてもつ数値行列を $\mathbf{R}, \mathbf{G}, \mathbf{B}$ とする．下記のように 1 次元画像 \vec{u} を作成する．

$$\left\{ \begin{array}{l} \vec{u}_R = \sum_{y=1}^N \mathbf{R}_y \\ \vec{u}_G = \sum_{y=1}^N \mathbf{G}_y \\ \vec{u}_B = \sum_{y=1}^N \mathbf{B}_y \\ \vec{u} = (\vec{u}_R, \vec{u}_G, \vec{u}_B) \end{array} \right. \quad (1)$$

ただし， $\mathbf{R}_y, \mathbf{G}_y, \mathbf{B}_y$ はそれぞれ $\mathbf{R}, \mathbf{G}, \mathbf{B}$ の第 y 行だけを取り出したベクトルである． N は列の数 (本研究では $N=320$)， \vec{u} は 960 列のベクトルとなる．

3.1.1 大きいハンドルで教師データ収集

教師データは，コースに障害物 (他のロボット, Fig.2 の黒い円囲まれてないロボット) をコースの中にランダムに置いて，データ収集ロボットをラジコンして，障害物と壁を避けながら時計回りと反時計回り両方走行して，教師データ収集する．障害物の位置もランダムに変更して，合計 3000 個教師データ収集した．

ラジコンの方法は table1 の大きいハンドルの部分を参照して，"D" 以外のボタンを押す瞬間の画像データを一次元画像データに変更して，ソケット通信で学習用パソコンに送信して，教師データの収集を行う．大きいハンドルというのは，ボタン"J"と"L"押すと，モーターの出力が 35 単位変えるということである．

3.1.2 小さいハンドルで教師データ収集

小さいハンドルで教師データ収集は大きいハンドルで教師データ収集と同じコースで収集する，障害物については，止まってるロボット約 6 台，感覚運動写像より走行するロボット 1 台，別の人がラジコンするロボット 2 台の環境で，データ収集ロボットをラジコンして，障害物と壁を避けながら時計回りと反時計回り両方走行して，教師データ収集する．合計 6000 個教師データ収集した．

ラジコンの方法は table1 の小さいハンドルの部分を参照して，ボタンを押す瞬間の画像データを一次元画像データに変更して，ソケット通信で学習用パソコンに送信して，教師データの収集を行う．小さいハンドルというのは，ボタン"J"と"L"押すと，モーターの出力が 15 単位変えるということである．

	小さいハンドル		大きいハンドル	
	Left motor	Right motor	Left motor	Right motor
W	+20	+20	+35	+35
S	-15	-15	-35	-35
A	*	*	-56	-56
D	*	*	=0	=0
J	-15	+15	-0	+35
L	+15	-15	+35	-0
K	操作 J と K で変化した出力が 0 になる			

Table. 1 大きいハンドルと小さいハンドルの違い




Fig. 2 データ収集



Fig. 3 ロボットの視点

3.2 データの学習

入力層：ニューロン数は 960 (一次元画像データの値の数)．

中間層：ニューロンの数を 100 から 1100 まで変更して，シミュレーションした．Fig.4 の横軸は中間層ニューロンの数，縦軸は左のモーターの予測出力と教師データ

出力の平均二乗誤差. Fig.5 の横軸は中間層ニューロンの数, 縦軸は右のモーターの予測出力と教師データ出力の平均二乗誤差. 中間層のニューロンの数の増加に従って, 回帰誤差の増減に規則性はみられない. 経験によって, 中間層のニューロンの数を 1000 にした.

出力層: 左右のモーターの制御パワーを計算するので, 出力層ニューロンの数が 2 にする.

活性化関数: relu 関数.

最適化アルゴリズム: Adam でバッチ学習である.

Adam のパラメーター: $\alpha=0.01$, $\eta=0.3$, $\beta_1=0.9$, $\beta_2=0.9$, $\epsilon=1 \times e^{-8}$, $w=0$.

Fig.6 と Fig.7 は学習終わったニューラルネットワークの回帰結果部分的グラフです. 横軸はデータの番号 (1 番目から 600 番目の教師データをグラフした), 縦軸は左のモーターの出力 (Fig.6) と右のモーターの出力 (Fig.7) です. ニューラルネットワークの予測出力が教師データの出力に完璧に回帰していないと見られるけど, 人間のラジコンで収集した教師データも完璧ではないと考えて, ある程度回帰できれば, 実際の走行実験の振舞いで評価するにした.




Fig. 4 中間層ニューロンの数と左のモーターの出力誤差




Fig. 5 中間層ニューロンの数と右のモーターの出力誤差




Fig. 6 NN で左のモーターの出力の回帰結果 (局部)




Fig. 7 NN で右のモーターの出力の回帰結果 (局部)

4 感覚運動写像

感覚運動写像とは, センサー値を変数とする関数によってモーターの出力を決定することであり, その瞬間のセンサー値だけを使う, 最も単純な反応行動のための知能の一つである [1]. 本研究では, 非線形感覚運動写像モデル (式 (2) と式 (3)) が使われている.

3 つの距離データを相乗平均する得られた x_L と x_R を式 (2) と式 (3) に代入して, ロボットの右モーターの出力 (m_R) と左モーターの出力 (m_L) を計算する. b は tanh 曲線の変曲点であり, 実験ではロボット曲がるの反応距離或いは障害物をぶつからない安全距離である. 今回の実験のパラメーターは $\alpha = 35\%$ とする. すなわちロボットは最高速度の 70% の速度で走行する. ニューラルネットワーク教師データ収集ラジコンする時の最高速度と同じです. $\beta_1 = 0.004$, $\beta_2 = 10$, $c = 0$ とする. 詳しい内容は参考文献 [2] を参考してください.

$$m_R = \alpha \tanh(\beta_1(x_L - b_L)) + \alpha \tanh(\beta_2(x_L - b_L)) + c \quad (2)$$

$$m_L = \alpha \tanh(\beta_1(x_R - b_R)) + \alpha \tanh(\beta_2(x_R - b_R)) + c \quad (3)$$

5 走行実験

本文は内側半径 1m の円と外側半径 2m の円で作られた幅 1m の円形コースで実験する. 内側のコース壁を薄青色に塗って, 外側のコース壁を青色の縞模様としている. 時計回りロボット 4 台と反時計回りロボット 4 台を 2 つずつセットにしてコースの中にランダムに置いて, 約 8 分間実験した. ロボットが自分の向きを判断できるため,

ロボットが破線 1 から反時計回りで破線 2 まで移動して, θ が 0 から π に変わる. 破線 1 から時計回りで破線 2 まで移動して, θ が 0 から $-\pi$ に変わる. R はロボットからコース中心までの距離である (Fig.8). それに, ロボットが反時計回りで破線 1 を通過したら, 通過回数 n_{ij} が +1, ロボットが時計回りで破線 1 を通過したら, 通過回数 n_{ij} が -1 になる. 次, ロボット一台ずつ, 各自の n_{ij} を計測して, 各ロボットの通過回数の絶対値を足し算して, 1 回の実験の通過回数になる. T_i は i 番目の実験の 1 方向走行流になる時間です (先行研究 [2] の T_{1d} と同じ, 単位: min), n_{ij} が T_i 以内の通過回数です, 1 方向走行流になった後の通過回数を捨てた. (4) 式で i 番目の実験の流量 Q_i を求めて, (5) 式で流量の平均値を求める. 本研究の流量が対面流の流量である. j はロボット

の番号で, k はロボットの台数です (今回の実験で 1 から 8 まで合計 8 台ロボットを使ったので, $k = 8$).

w がコースの幅 (単位:m), N_{exp} は全実験回数を表す.

ロボットが渋滞状態を解消する能力も比較するため, 2 つロボットをペアとして, ランダムの初期配置 (Fig.9) と渋滞の初期配置 (Fig.10) の実験を行った




Fig. 8 実験の様子 (俯瞰図) と θ の説明

$$Q_i = \frac{\sum_{j=1}^k |n_{ij}|}{wT_i} \quad (4)$$

$$\bar{Q} = \frac{1}{N_{\text{exp}}} \sum_{i=1}^{N_{\text{exp}}} Q_i \quad (5)$$




Fig. 9 ランダムの初期配置

Fig. 10 渋滞の初期配置

6 実験結果

6.1 小さいハンドル教師データでの走行

我々はまず小さいハンドル教師データを学習した結果で, ランダムの初期配置によって 8 台ロボット対面走行を実験した. Fig.11 は時間 (s 横軸) と θ (縦軸上), R (縦軸下) の関係図です. この実験から, 一部のロボット達が短時間の対面走行できると確認したけど, ロボット同士がぶつかる, 壁にぶつかる, 引っかかって解消不能, 方向転換なども観察された.

例として, 左の上から 3 番目, 右の上から 2 番目と 3 番目のグラフで, θ の変動が止まって, 水平になった, Fig.12 は約 400 秒 θ が水平になる部分に対する実験風景です, 実験からロボットが壁にぶつかって, 後退しなくて, 止まっちゃう, 2 つロボットが引っかかって解消不能になって, 止まっちゃうことが観察された. 原因として, 曲がりと後退のパワーが弱いと考えて, 大きいハンドルのラジコンで教師データを収集して実験した, 実験結果は次に説明する.

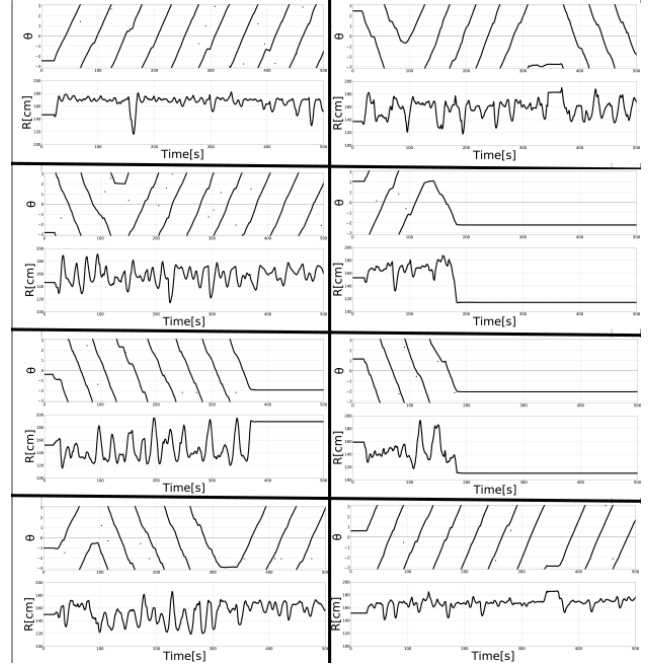


Fig. 11 小さいハンドル NN, 8 台ロボットの走行結果




Fig. 12 小さいハンドル NN 走行実験 400 秒の様子

6.2 感覚運動写像と走行の比較

ラジコンの曲がる値が拡大して (大きいハンドル) 収集した教師データの学習結果での自律走行実験も約 6 回行った. Fig.13 と Fig.14 はニューラルネットワークにより走行と $b = 270, 270$ の感覚運動写像により走行の 1 回

の走行実験の時間変化におけるロボット位置の角度 (θ) と半径 (R) のまとめ図である。横軸は時間 (s), 縦軸上のほうが θ , 下のほうが R である。

この2つグラフから、大きいハンドルでのニューラルネットワークよりの走行のほうが対面走行を最後まで維持でき、スムーズに走れると観察された (Fig.15, 時計回りのロボット達が内側の壁に沿う, 反時計回りのロボット達が外側の壁に沿う)。

$b = 270, 270$ の感覚運動写像よりの走行のほうが途中に1方交流になった (Fig.14, 約250秒からすべての θ の曲線が右に傾斜する), R の変動範囲が大きい (衝突が多い), 1方向走行流になったら, R の変動も安定になって, 外側の壁に沿って反時計回り走ると観察された (Fig.16)。

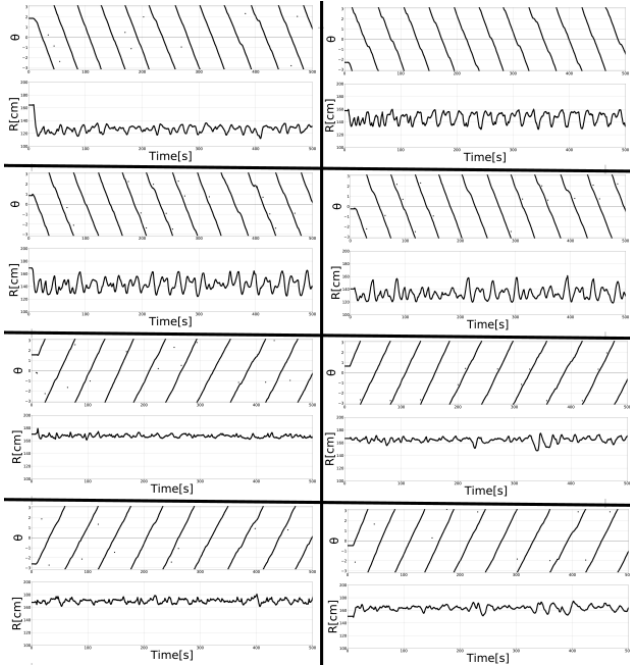


Fig. 13 ランダムの初期配置で NN により走行の θ, R と時間の関係図

6.3 感覚運動写像と流量の比較

流量を比較するため, ランダムと渋滞, 2種類の初期配置でニューラルネットワークより, 感覚運動写像より約5回実験した。Fig.17とFig.18は2種類の初期配置での実験回数 (x 軸) と流量 (y 軸) の関係図です。

点線がニューラルネットワークより走行の結果, 実線が $b = 270, 270$ の感覚運動写像より走行の結果, 一点鎖線が $b = 360, 260$ の感覚運動写像より走行の結果です。ニューラルネットワークの流量が常に感覚運動写像の流量より高い, 変動も平穏だと見られる。

Fig.19はランダムの初期配置 (実線) と渋滞の初期配置 (一点鎖線) で約5回の実験の流量平均値グラフです。

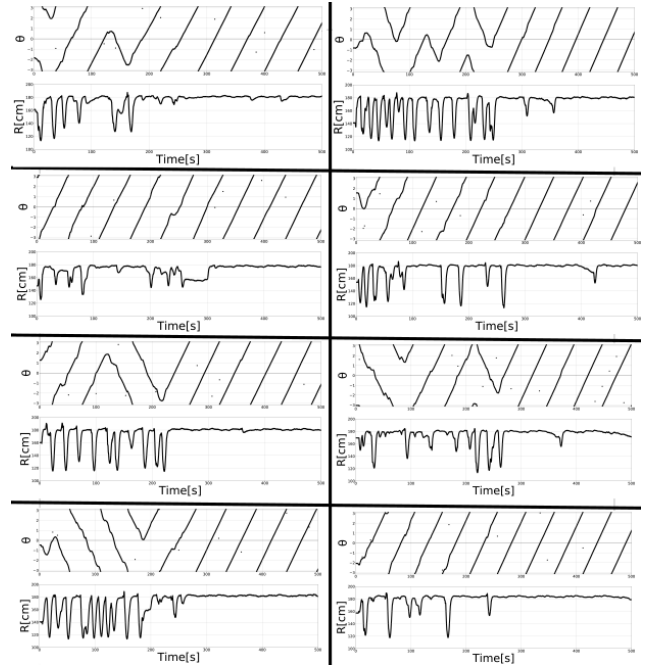


Fig. 14 ランダムの初期配置で SMM により走行の θ, R と時間の関係図




Fig. 15 300 秒 neural net- work 走行風景
Fig. 16 300 秒感覚運動写像走行風景

x 軸はアルゴリズム種類, y 軸は平均流量。この図からニューラルネットワークの平均流量も感覚運動写像より高く, 異なる初期配置に対して平均流量があんまり変わらない。 $b = 270, 270$ の感覚運動写像の平均流量が初期配置によって差が観察されて, それは実験の回数が不足かなと考えて, 今後, 実験の回数を増やす必要があると思う。

7 まとめ

1次元画像データ認識ニューラルネットワークより8台ロボットが縞模様のコースで対面走行ができると確認した。感覚運動写像と比べて, 方向転換教えなくても, 対面走行を維持する能力が高い。

本文説明した対面走行維持できるニューラルネットワークの学習結果は, 著者が何十回練習して, 経験を踏




Fig. 17 ランダムの初期配置で実験回数により流量の変化図




Fig. 18 渋滞の初期配置で実験回数により流量の変化図




Fig. 19 異なるアルゴリズムの平均流量の比較

の学習結果では自律走行ができないことが観察された, その原因として, 画像を列ずつ足し算してもらった1次元画像データが障害物と通路の特徴を失って, 区別できなくなると考える.

今後の展望として, 色んな教師データの違いと特徴を分析して, どんな教師データがあれば対面走行維持できるを解明すると教師データの質を評価方法を開発する必要がある. また, 画像エントロピーで環境の複雑度を評価して1次元画像データの限界を解明すると考える.

参考文献

- [1] 浅田稔, 国吉康夫「ロボットインテリジンス」(2006).
- [2] 李 方正, 橋爪晋平, 本田泰.「非線形感覚運動写像ロボットの対面流-1 方向走行流への転移と流量のコース幅依存性-」第26回交通流と自己駆動粒子系シンポジウム論文集 (2020)

まえ, ラジコンする時, 遠くから曲がる, 近づいて曲がる, 真正面にロボットや壁ある時後退することをわざわざ人間の意識持ってロボットに教えて収集した教師データの学習結果です, 研究室の他の人がラジコンして収集した教師データも学習して, 自律走行の質もそれぞれだ. それに, コースの壁の代わりに, 別のもの(ダンボール, 雑誌, サンドルなど)を配置して, 収集した教師データ