

画像認識ニューラルネットワークによる複数ロボットの対面走行

○李 方正 (室蘭工業大学), 山田 将司 (室蘭工業大学), 本田 泰 (室蘭工業大学)

Bidirectional movements of multiple robots based on a neural network for image recognition

○Li Fangzheng (Muroran Institute of Technology), Masashi Yamada (Muroran Institute of Technology), Yasushi Honda (Muroran Institute of Technology)

Abstract:

Collective motions of many self-driven objects are observed in various situations. For example, human crowds, car traffics, swarm bird, biological cells, swarm robot and so on are famous as such collective motions. In previous study, we carried out experiments about a bidirectional movement with Seasory-Motor-Mapping (SMM) robots based on a nonlinear function in pseudo-ellipse course. We found a transition phenomenon from bidirectional movement to unidirectional flow. In this study, we made a neural network (NN) model which can recognize a one-dimensional image and make autonomous movements of small robots in a simple circuit. And we compare their trajectories and flow rate with them for SMM robots in same circuit. From those experiments we found that the NN with one-dimensional image can make robots avoid obstacles smoothly and keep bidirectional movement for a long time successfully. Moreover, we also proved the neural network model is better than seasory motor mapping model in robots flow rate, time of keep one-direction flow and turn around number in our simple circuit.

Keywords: Swarm robot, Autonomous movement, Bidirectional movement, Neural network, Seasory motor mapping

1 はじめに

実世界では、蜂、アリなどの昆虫の簡単な行動メカニズムによる複雑な群れ行動がよく観察される。また、大きな交差点などにおいて、人間は密度が高くても、会話しで、ぶつからないようにスムーズに対面歩行ができる。その他にも自動車の交通流や生物細胞など、自己駆動粒子の集団運動は至るところで観察され、その発生メカニズムには興味深いものがある。しかし人間の集団歩行を例に取れば分かるとおり、その行動メカニズムすなわち行動アルゴリズムは必ずしも明確ではない [1]。

我々は、走行ロボットを使って、様々な自律走行アルゴリズムで走行実験を行い、その隊列走行など、群ロボットの自己組織化現象について研究を行っている。群衆の対面歩行におけるレーン形成などと比較することができれば、その生成メカニズムを推測する手がかりになることが期待できる。

先行研究 [2] では、我々は双曲線関数により、距離センサとモーターの出力が直接関連する感覚運動写像 (省略名: SMM) ロボットを使って、擬楕円コースで8台のロボットの対面走行の実験を行った。結果として、コース幅の増加に従って、流量が増加して、コース幅がロボットサイズの約 1.8 倍程度から自律走行が安定することを確認した。初期配置と初期向きを問わず、一定時間走行後、すべてのロボットが同じ方向になって、1 方向走行流が観察された。理由として、距離情報だけでは、向きを判断できないため考えている。また、3 つの距離データで障害物の数を認識できず、渋滞が起こることの原因になると考える。

本研究では、長時間対面歩行ができ、流量を増やせる

ようにするため、カメラを使って、中間層 1 層のニューラルネットワーク (省略名: NN) により 1 次元画像認識アルゴリズムを開発した。コースに色をつけ、感覚運動写像とニューラルネットワーク 2 種類のアルゴリズムでコース幅 1m の 8 台ロボットの対面走行実験を行った。

モーションキャプチャによってロボットの走行軌道を観測し、その流量を求めた。感覚運動写像より、ニューラルネットワークの方が壁や障害物 (他のロボット) をスムーズに避けることができることを観察した。流量も約 1.5 倍になると確認した。

また教師データを作成する際に、モーター駆動の変化量を相対的に極端にする (大きなハンドル) 方がニューラルネットワークによる自律走行性能が向上することが明らかとなった。

2 ロボットの身体性

今回使っているのはラズパイで制御する 4 輪走行ロボットである (Fig.2), 人間や昆虫の走行特徴に近似するため、その場で曲がり、方向転換が可能である。ロボットの頭にカメラ (D) をつけていて、入力データを収集する。E, F は左右のモーター、独自で左右の車輪を制御して、ロボットを動かす。A, B, C は右, 中央, 左の距離センサーであり、感覚運動写像において用いる [2]。ロボット幅は 13.5cm。長さは 20.2cm。高さは 12.2cm である。




Fig. 1 ロボット正面図

3 ニューラルネットワーク

3.1 教師データの収集

本研究では、二次元画像データ (RGB) のピクセル値を縦方向 (y 方向) にすべて足し合わせて一次元画像をつくる。それらを並べたものを 1 次元画像ベクトル \vec{u} とする (1 式参照)。

具体的に記述する。カメラで撮影するのは 320×240 のサイズのピクセル値であるが、不要な部分を切り取って、130 行目から 200 行目を切り出す。コースの壁や障害物となる走行ロボット以外が撮影されている上下の部分を不要な部分とみなす。つまりコース以外とロボット自身が映ってる部分をトリミングする (Fig.2 参照)。

その画像データの Red, Green, Blue それぞれのピクセル値を要素としてもつ数値行列を $\mathbf{R}, \mathbf{G}, \mathbf{B}$ とする。下記のように 1 次元画像 \vec{u} を作成する。

$$\left\{ \begin{array}{l} \vec{u}_R = \sum_{y=130}^{200} \mathbf{R}_y \\ \vec{u}_G = \sum_{y=130}^{200} \mathbf{G}_y \\ \vec{u}_B = \sum_{y=130}^{200} \mathbf{B}_y \\ \vec{u} = (\vec{u}_R, \vec{u}_G, \vec{u}_B) \end{array} \right. \quad (1)$$

ただし、 $\mathbf{R}_y, \mathbf{G}_y, \mathbf{B}_y$ はそれぞれ $\mathbf{R}, \mathbf{G}, \mathbf{B}$ の第 y 行だけを取り出したベクトルである。 \vec{u} は 960 列のベクトルとなる。



Fig. 2 ロボットの視点からのカメラ画像例

3.1.1 大きいハンドルで教師データ収集

教師データは、コースに障害物 (他のロボット, Fig.3 の黒い円で囲まれてないロボット) をコースの中にランダムに置いて、データ収集ロボットを手動操縦 (ラジコ

ン) して、障害物と壁を避けながら時計回りと反時計回り両方走行して、教師データ収集する。障害物の位置もランダムに変更して、合計 3000 個教師データ収集した。




Fig. 3 円形サーキット

ラジコンの方法は Table.1 の大きいハンドルの部分を参照して、“D”以外のボタンを押す瞬間の画像データを一次元画像データに変更して、ソケット通信で学習用パソコンに送信して、教師データの収集を行う。大きいハンドルというのは、ボタン“J”と“L”を押すと、モーターの出力が 35 単位変えるということである。

Table. 1 大きいハンドルと小さいハンドルの違い

	小さいハンドル		大きいハンドル	
操作	Left motor	Right motor	Left motor	Right motor
W	+20	+20	+35	+35
S	-15	-15	-35	-35
A	*	*	-56	-56
D	*	*	=0	=0
J	-15	+15	-0	+35
L	+15	-15	+35	-0
K	操作 J と K で変化した出力が 0 になる			

3.1.2 小さいハンドルで教師データ収集

小さいハンドルで教師データ収集は大きいハンドルで教師データ収集と同じコースで収集する。障害物については、止まってるロボット約 6 台、感覚運動写像より走行するロボット 1 台、別の人がラジコンするロボット 2 台の環境で、データ収集ロボットをラジコンして、障害物と壁を避けながら時計回りと反時計回り両方走行して、教師データ収集する。合計 6000 個教師データ収集した。

ラジコンの方法は Table.1 の小さいハンドルの部分を参照して、ボタンを押す瞬間の画像データを一次元画像データに変更して、ソケット通信で学習用パソコンに送信して、教師データの収集を行う。小さいハンドルというのは、ボタン”J”と”L”押すと、モーターの出力が 15 単位変えるということである。

3.2 データの学習

入力層のニューロン数は 960(一次元画像データの値の数)とした。中間層のニューロンの数を 100 から 1100 まで変更して、学習を行った。Fig.4 の横軸は中間層ニューロンの数、縦軸は左のモーターの予測出力と教師データ出力の平均二乗誤差である。Fig.5 の横軸は中間層ニューロンの数、縦軸は右のモーターの予測出力と教師データ出力の平均二乗誤差である。中間層のニューロンの数の増加に従って、回帰誤差の増減に規則性はみられない。経験によって、中間層のニューロンの数を 1000 にした。

左右のモーターの制御パワーを計算するので、出力層ニューロンの数を 2 にする。活性化関数として relu 関数を用いた。

最適化アルゴリズムとして Adam でバッチ学習を用いた。

Adam のパラメーターとして $\alpha=0.01$, $\eta=0.3$, $\beta_1=0.9$, $\beta_2=0.9$, $\epsilon=1 \times e^{-8}$, $w=0$ を用いた。

Fig.6 と Fig.7 は学習終わったニューラルネットワークの回帰結果部分的グラフである。横軸はデータの番号 (1 番目から 600 番目の教師データをグラフした), 縦軸は左のモーターの出力 (Fig.6) と右のモーターの出力 (Fig.7) である。ニューラルネットワークの予測出力が教師データの出力に完璧に回帰していないと見られるが, 人間のラジコンで収集した教師データも完璧ではないと考えて, ある程度回帰できれば, 実際の走行実験の振舞いで評価を行う。




Fig. 4 中間層ニューロンの数と左のモーターの出力誤差




Fig. 5 中間層ニューロンの数と右のモーターの出力誤差




Fig. 6 NN で左のモーターの出力の回帰結果 (局部)




Fig. 7 NN で右のモーターの出力の回帰結果 (局部)

4 感覚運動写像

感覚運動写像とは、センサー値を変数とする関数によってモーターの出力を決定することであり、その瞬間のセンサー値だけを使う、最も単純な反応行動のための知能の一つである [3]。本研究では、非線形感覚運動写像モデル (式 (2) と式 (3)) が使われている。

3 つの距離データを相乗平均することで得られた x_L と x_R を式 (2) と式 (3) に代入して、ロボットの右モーターの出力 (m_R) と左モーターの出力 (m_L) を計算する [2]。 b は tanh 曲線の変曲点であり、ロボットの反応距離或いは障害物にぶつからない安全距離である。今回の実験のパラメーターは $\alpha = 35\%$ とする。すなわちロボットは最高速度の 70% の速度で走行する。ニューラルネットワーク教師データ収集ラジコンする時の最高速度と同じ値である。 $\beta_1 = 0.004$, $\beta_2 = 10$, $c = 0$ とする (詳しい内容は参考文献 [2])。

$$m_R = \alpha \tanh(\beta_1(x_L - b_L)) + \alpha \tanh(\beta_2(x_L - b_L)) + c \quad (2)$$

$$m_L = \alpha \tanh(\beta_1(x_R - b_R)) + \alpha \tanh(\beta_2(x_R - b_R)) + c \quad (3)$$

5 走行実験

本研究では内側半径 1m の円と外側半径 2m の円で作られた幅 1m の円形コースで実験する。内側のコース壁を薄青色に塗って、外側のコース壁を青色の縞模様としている。時計回りロボット 4 台と反時計回りロボット 4

台を2つずつセットにしてコースの中にランダムに置いて、約8分間実験した。

ロボットが破線1から反時計回りで破線2まで移動して、 θ が0から π に変わる。破線1から時計回りで破線2まで移動して、 θ が0から $-\pi$ に変わる。 R はロボットからコース中心までの距離である (Fig.8)。




Fig. 8 実験の様子 (俯瞰図) と θ の説明

実験 i の j 番目のロボットの周回数を n_{ij} とする。すなわち、ロボットが反時計回りで破線1を通過したら、通過回数 n_{ij} に +1、ロボットが時計回りで破線1を通過したら、通過回数 n_{ij} に -1 する。各ロボットの通過回数の絶対値を足し算して、1 回の実験の流量 Q_i になる。

$$Q_i = \frac{\sum_{j=1}^k |n_{ij}|}{wT_i} \quad (4)$$

$$\bar{Q} = \frac{1}{N_{\text{exp}}} \sum_{i=1}^{N_{\text{exp}}} Q_i \quad (5)$$

T_i は i 番目の実験の 1 方向走行流になる時間である (先行研究 [2] の T_{1d} と同じ, 単位:min), n_{ij} が T_i 以内の通過回数である。1 方向走行流になった後の通過回数は流量に含めないこととする。(4) 式で i 番目の実験の流量 Q_i を求めて、(5) 式で流量の平均値を求める。本研究の流量が対面流の流量である。 k はロボットの台数である (今回の実験で 1 から 8 まで合計 8 台ロボットを使ったので $k = 8$)。

w がコースの幅 (単位:m), N_{exp} は全実験回数を表す。

ロボットが渋滞状態を解消する能力も比較するため、2つロボットをペアとして、ランダムの初期配置 (Fig.9) と渋滞の初期配置 (Fig.10) の実験を行った

6 実験結果

6.1 小さいハンドル教師データでの走行

我々はまず小さいハンドル教師データを学習した結果で、ランダムの初期配置によって 8 台ロボット対面走行




Fig. 9 ランダムの初期配置 Fig. 10 渋滞の初期配置 (Random) (Crowd)

を実験した。Fig.11 は時間 s (横軸) と θ (縦軸上), R (縦軸下) の関係図である。この実験から、一部のロボット達が短時間の対面走行できると確認したが、ロボット同士がぶつかる、壁にぶつかる、引っかかって解消不能、方向転換なども観察された。例として、左の上から3番目、右の上から2番目と3番目のグラフで、 θ の変動が止まって、水平になった、

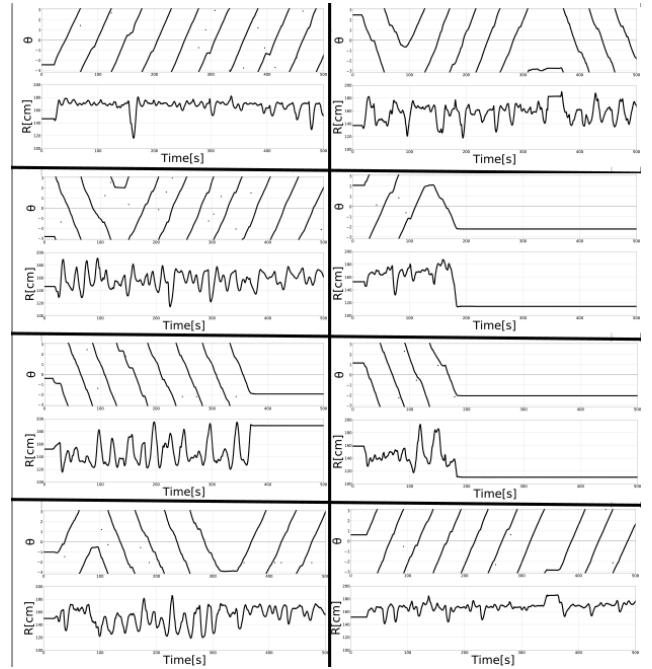


Fig. 11 小さいハンドル教師データを用いた NN による 8 台ロボットの自律走行軌道。ロボット同士の膠着状態 (図中 θ, R の値が一定値になる) が観測された。また方向転換が行われ対称的な対面流が崩壊している。

Fig.12 は約 400 秒 θ が水平になる部分に対する実験風景である。実験からロボットが壁にぶつかって、後退しなくて停止する。2つロボットが引っかかって解消不能になって、膠着状態が観察された。原因として、曲がりと後退のパワーが弱いと考えて、大きいハンドルのラジコンで教師データを収集して実験した。実験結果は次に

説明する.




Fig. 12 小さいハンドル NN 走行実験 400 秒の様子

6.2 感覚運動写像と走行の比較

ラジコンの曲がる値を拡大して (大きいハンドル) 収集した教師データの学習結果での自律走行実験も約 6 回行った. Fig.13 と Fig.14 はニューラルネットワークによる走行と $b = 270, 270$ の感覚運動写像による走行の 1 回の走行実験の時間変化におけるロボット位置の角度 (θ) と半径 (R) のまとめ図である. 横軸は時間 (s), 縦軸上のほうが θ , 下のほうが R である.

この 2 つグラフから, 大きいハンドルでのニューラルネットワークの走行のほうが対面走行を最後まで維持でき, スムーズに走れると観察された (Fig.15). 時計回りのロボット達が内側の壁に沿う, 反時計回りのロボット達が外側の壁に沿う.

$b = 270, 270$ の感覚運動写像によりの走行のほうが途中に 1 方交流になった (Fig.14. 約 250 秒からすべての θ の曲線が右に傾斜する), R の変動範囲が大きい (衝突が多い), 1 方向走行流になったら, R の変動も安定になって, 外側の壁に沿って反時計回り走ると観察された (Fig.16).

6.3 感覚運動写像と流量の比較

流量を比較するため, ランダムと渋滞, 2 種類の初期配置で実験した. Fig.17 と Fig.18 は 2 種類の初期配置での実験回数 (x 軸) と流量 (y 軸) の関係図である.

点線がニューラルネットワークによる走行の結果, 実線が $b = 270, 270$ の感覚運動写像による走行の結果, 一点鎖線が $b = 360, 260$ の感覚運動写像による走行の結果である. ニューラルネットワークの流量が常に感覚運動写像の流量より高い, 変動も少ない.

Fig.19 はランダムの初期配置 (実線) と渋滞の初期配置 (一点鎖線) で約 5 回の実験の流量平均値グラフである. x 軸はアルゴリズム種類, y 軸は平均流量を表す. この図からニューラルネットワークの平均流量は感覚運動写像より高く, 異なる初期配置に対して平均流量が変

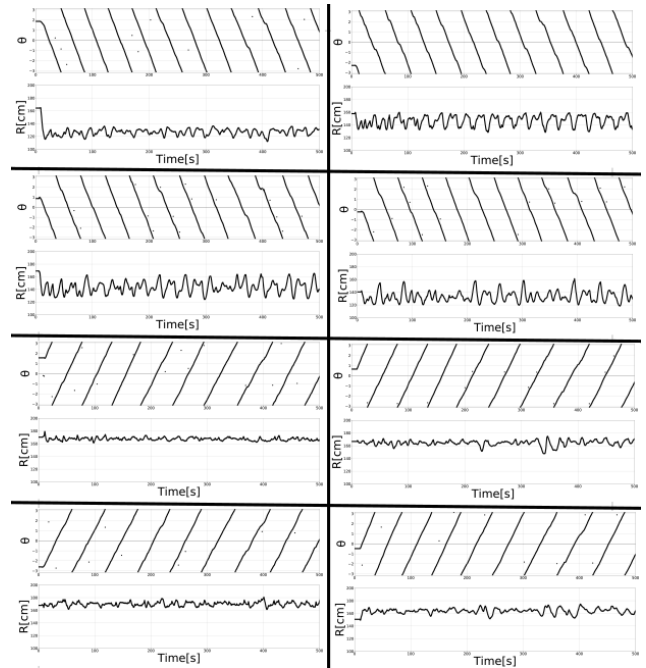


Fig. 13 ランダムの初期配置で NN により走行の θ, R と時間の関係図

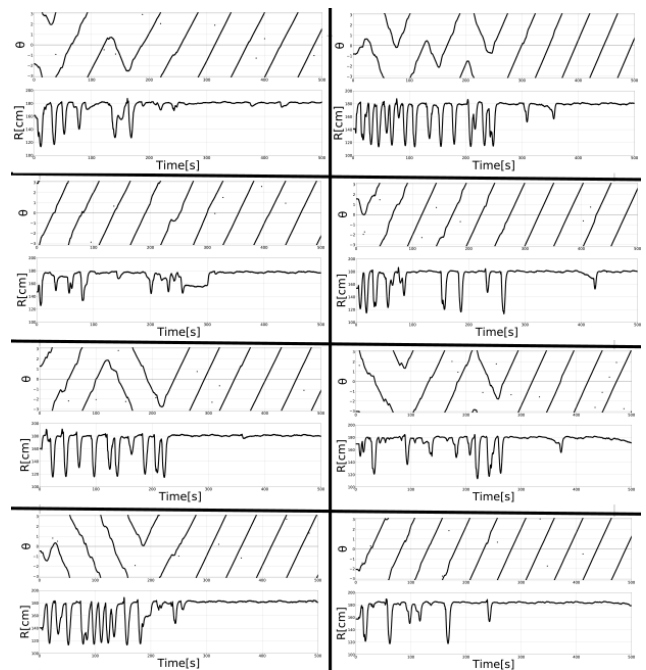


Fig. 14 ランダムの初期配置で SMM により走行の θ, R と時間の関係図

わらない. $b = 270, 270$ の感覚運動写像の平均流量が初期配置によって差が観察されて, それは実験の回数が不足と考えられ, 今後, 実験の回数を増やす必要がある.




Fig. 15 300 秒 neural net- work 走行風景 Fig. 16 300 秒感覚運動写像走行風景

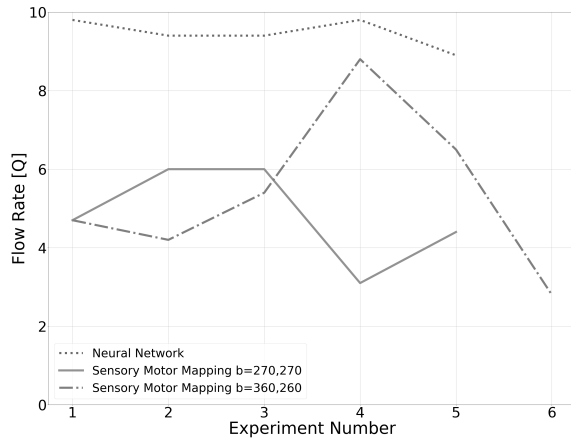


Fig. 17 ランダムの初期配置で実験回数により流量の変化図




Fig. 18 渋滞の初期配置で実験回数により流量の変化図

7 まとめ

1次元画像データ認識ニューラルネットワークにより8台ロボットが縞模様のコースで対面走行ができると確認した。感覚運動写像と比べて、方向転換を教えなくても、対面走行を維持する能力が高い。

対面走行維持できるニューラルネットワークの学習結果は、著者が何十回と練習して、経験を踏まえ、ロボットを操縦する時、遠くから曲がる、近づいて曲がる、真




Fig. 19 異なるアルゴリズムの平均流量の比較

正面にロボットや壁がある時後退することをわざわざ人間の意識持ってロボットに教えて収集した教師データの学習結果である。著者以外の人々がラジコン操縦して収集した教師データを学習しても、必ずしも本論文で示した自律走行の質が再現できるとは限らない。教師データが備えるべき客観的性質を定量的に測定することが今後の課題である。このことは人間が群衆の中で対面歩行する際の具体的なアルゴリズムを考察する上で貴重な示唆を与えられられる。

また、コースの壁の代わりに、別のもの(ダンボール、雑誌、サンダルなど)を配置して、収集した教師データの学習結果では自律走行が困難であることが観察された。その原因として、画像の列ずつ足し算してつくった1次元画像データが障害物と通路の特徴を失って、区別できなくなると考えられる。

今後の展望として、さまざまな教師データに対する自律走行実験を行い、特徴を分析して、どのような教師データがあればスムーズな対面走行を維持できるかを明らかにしたい。そのためには教師データの質の評価方法を開発する必要がある。また、画像エントロピーで環境の複雑度を評価して1次元画像データの限界を解明したいと考えている。

参考文献

- [1] H.Murakami, C.Feliciani, Y.Nishiyama and K. Nishinari, "Mutual anticipation can contribute to self-organization in human crowds" Vol 7 Issue 12 Science Advances (2021).
- [2] 李 方正, 橋爪晋平, 本田泰.「非線形感覚運動写像ロボットの対面流-1 方向走行流への転移と流量のコース幅依存性-」第26回交通流と自己駆動粒子系シンポジウム論文集 (2020)
- [3] 浅田稔, 国吉康夫「ロボットインテリジンス」(2006).